

01. LangChain : AI 연결의 패러다임 시프트

거대언어모델(LLM)과 다양한 외부 도구를 연결하여 실질적인 자율형 비즈니스 서비스를 구축하는 오픈소스 엔진

ETYMOLOGY & DEFINITION

Language Model + Chain

언어 모델에 강력한 "연결 고리"를 더하다

LLM은 홀로 존재할 때 똑똑한 두뇌에 불과하지만, 주변 환경과 연결되지 못해 고립되어 있습니다. 랭체인은 이 똑똑한 두뇌에 손과 발(API), 기억(Memory), 그리고 눈(Data)을 달아주는 파이프라인 프레임워크입니다.


CORE VALUE

각기 규격이 다른 AI 모델, 데이터베이스, 웹 API 등을 유기적인 체인처럼 조합하여 실전 비즈니스 가치를 자동 산출합니다.

ARCHITECTURE VISUALIZATION

랭체인이 설계하는 무결한 연결 파이프라인

외부 인프라를 체인으로 엮어 완성하는 현대적 AI 오케스트레이션



작업 흐름 제어의 단일화: 랭체인은 이 독립적인 4대 모듈을 단 한 줄의 체인 표현식(`LCEL`)으로 간결하게 결합시켜, 중간 단계의 유실 없이 신뢰도 높은 데이터를 흐르게 유도합니다.

02. 랭체인 핵심 기능 (1) : 모델 추상화 & 기억 장치

기종 교체가 자유로운 유연한 설계 인프라와 단기/장기 연속성 보장을 위한 대화 관리 기법

01. MODEL ABSTRACTION



모델 추상화 (Model Abstraction)

LLM 공급사(OpenAI, Anthropic, Google 등)에 관계없이 단 하나의 공통 인터페이스로 코드 변경 없이 모델을 자유롭게 스왑(Swap)합니다.



직관적인 추상화 비유: 자동차 운전

"운전자는 엔진의 고유 연소 방식이나 기어박스의 내부 작동 구동 방식을 알지 못해도, 시동을 걸고 핸들을 돌려 전진(D)할 수 있습니다. 랭체인은 복잡한 AI 모델 내부를 자동차 새시처럼 표준 인터페이스로 감싸줍니다."

비즈니스 안정성 수호: 특정 AI 업체의 종속(Vendor Lock-in)을 막고 가격 인하 및 성능 고도화 시그널에 맞춰 즉각적인 백업 전환 환경을 확보합니다.

02. MEMORY INJECTION



기억 장치 추가 (Memory)

LLM API는 기본적으로 '무상태(Stateless)'로서 직전 대화를 완벽히 지워버립니다. 랭체인은 대화 이력을 버퍼에 누적해 AI가 문맥을 유지하게 조율합니다.



ChatGPT는 순수한 LLM이 아닙니다

"ChatGPT는 LLM 엔진 자체가 혼자 기억하는 것이 아닙니다. LLM이라는 핵심 두뇌 뒤에 대화 기록 장치(Memory System)를 연동한 별도의 완결된 애플리케이션인 것입니다."

대화 세션 흐름 관리: 토큰 소모를 방지하기 위해 이전 대화에서 중요한 핵심 요약본만 추출하여 압축 주입하는 지능형 메모리 버퍼를 지원합니다.

03. 랭체인 핵심 기능 (2) : RAG & 자율 에이전트

사내 데이터 보안 자산의 정밀 연계와 도구 자율 호출을 통한 고차원 해결 능력

03. RETRIEVAL-AUGMENTED GENERATION

외부 데이터 정밀 연계 (RAG)

LLM이 전혀 학습하지 못한 실시간 웹 정보, 최신 트렌드, 자사 내부 보안 규정 문서(PDF, DB, Notion)를 검색하여 답변에 반영시킵니다.

RAG 3-STEP PIPELINE

- 1 검색 (Retrieve): 사용자의 질의와 부합하는 관련 파일 문맥 검색
- 2 보강 (Augment): 검색된 실제 사실 데이터 프롬프트 자동 조립
- 3 생성 (Generate): 팩트 가이드를 기준으로 거짓(환각) 없는 답변 생성

할루시네이션 극복: 대규모 사내 문서 데이터베이스를 조각내어 최적의 구간을 가져오는 정합성 로더를 내장 지원합니다.

04. INTELLIGENT ACTION AGENT

도구 자율 결합 (Agent)

LLM이 스스로 판단하여 구글 검색, 이메일 전송, 슬랙 알림, 사내 Git 레포지토리 API 호출 등 외부 자원을 직접 작동하도록 돕습니다.


AGENT REASONING LOOP

THOUGHT: 사용자의 복합적인 전체 질문을 인식하고 판단 단계 설정

ACTION: Google Calendar API 호출 결정

OBS: 도구로부터 리턴받은 실행데이터를 확인하고 메일 자동 전송

자율 비서의 핵심 아키텍처: 스스로 도구 리스트를 탐색하고 다음 행동 양식을 유지하는 강한 계획형 추론 체인을 구성합니다.



01. RAG (검색 증강 생성) : 외부 지식과 지능의 결합

거대 언어 모델(LLM)이 가진 정보의 한계와 환각 현상(Hallucination)을 사내 정보 보정 검색망을 통해 물리적으로 격파하는 아키텍처입니다.

BACKGROUND PHILOSOPHY

시험장에 사내 규정 족보를 가지고 입장하는 시험자

순수 LLM은 아무런 자료 없이 자기 기억만으로 문제를 푸는 '폐쇄형 시험(Closed Book)' 상태입니다. 아무리 똑똑해도 모르는 사내 복지나 신규 스펙이 나오면 그럴듯한 거짓말을 지어내게 됩니다.

RAG는 질문과 일치하는 문서 조각들을 검색망을 통해 빠르게 수집한 뒤, 그 자료들을 LLM에게 건네며 '이 자료 안에서만 대답해(Open Book)'라고 지시하여 정확성을 보장합니다.

CORE ENGINE

RAG의 핵심은 자료 뭉치에서 가장 정답에 가까운 내용을 컴퓨터가 알아듣는 숫자의 크기로 변환하여 비교 탐색하는 '문장 임베딩(Sentence Embedding)' 기술입니다.

INTERACTIVE PIPELINE BLUEPRINT

RAG 아키텍처 수집-검색-생성 통합 데이터 파이프라인

외부 원천 문서를 조각내어 저장하고, 질문과 일치하는 벡터를 수집해 답변을 빚어내는 전 과정



파이프라인 통제: RAG 아키텍처는 원천 문서를 숫자 벡터 공간에 매핑해 두는 "사전 수집 과정(오프라인)"과, 질문이 들어왔을 때 관련 정보를 취합하여 LLM에게 주입하는 "실시간 추론 과정(온라인)"의 상호 작용으로 작동됩니다.

02. 데이터 구축 단계 : ① 청크 분할 및 ② 벡터 저장

사내 데이터 원천 자산을 기계가 고도로 인지할 수 있도록 가공하여 지식 정보 인프라를 구축하는 사전 작업

STEP 01. CHUNKING PIPELINE



① 데이터 준비 및 청크(Chunk) 분할

책이나 사내 법률/복지 문서처럼 긴 통 텍스트는 한 번에 모델에 집어넣기 비효율적이며 임베딩 시 중요한 맥락이 희석됩니다. 따라서 문맥과 가독성이 끊기지 않도록 글자 수(예: 300자~500자) 기준으로 텍스트를 정밀 컷팅합니다.

</> Chunking Simulation

Chunk 1 "...당사는 임직원들의 인락한 주거 복지를 제공하기 위하여 [주택 임차 자금 대출 지원 제도]를 상시 운용합니다..."

Chunk 2 "...임차 대출 한도는 최대 1억 원 이내이며 연 금리 1.5% 우대 금리를 대입해 소속 주임급 이상 사원에게 수혜 자격을 부여..."

슬라이딩 윈도우 기법: 문맥이 절단선에서 임의 유실되는 것을 막기 위해 청크 간 일정 영역(예: 50자~100자)을 겹치게 (Overlap) 분할하는 정확성을 확보합니다.

STEP 02. VECTOR DB STORAGE



② 문서 임베딩 및 벡터 DB 저장

쪼갠 각각의 청크 텍스트를 인공지능 임베딩 모델(예: OpenAI Ada, bge-m3)에 밀어 넣어, 고차원 공간 속의 실수 좌표 배열인 **숫자 벡터(Vector)**로 변환한 후 벡터 인덱스 DB에 영구 적재합니다.



주요 상용 벡터 데이터베이스 예시

Pinecone

Cloud Only

Milvus

Enterprise

Chroma DB

Lightweight

FAISS

Meta Open

고속 다차원 검색: 벡터 DB는 수억 개의 다차원 좌표 사이에서 공간적 거리가 유사한 문장을 0.01초 이내에 검색하는 K-최근접 이웃(KNN) 전용 색인 알고리즘을 수행합니다.

03. 실시간 추론 단계 : ③ 유사도 검색 및 ④ LLM 생성

사용자의 질문이 인입되는 실시간 상황에서, 질문 벡터와 가장 일치하는 문맥을 찾아내고 이를 조합해 무결 답변을 창조하는 과정

STEP 03. COSINE SIMILARITY MATCHING

③ 질문 임베딩 및 코사인 유사도 검색

사용자의 질문이 서버에 입력되면 즉시 동일한 임베딩 모델로 전향 변환합니다. 그 후 벡터 데이터베이스 속에서 질문 벡터와 **방향(각도)의 정합성이 가장 일치하는 코사인 유사도(Cosine Similarity)** 최상위 청크를 선별해 냅니다.

코사인 유사도 산출 공식

$$\text{similarity} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{||\mathbf{A}|| \cdot ||\mathbf{B}||}$$

- **1.0 (0도):** 두 문장의 의미 완전 일치
- **0.0 (90도):** 독립적이고 무관한 문장
- **-1.0 (180도):** 정반대 및 상치되는 의미

콘텐츠 주입: 키워드가 100% 일치하지 않고 질문에 동의어 및 축약어가 섞여 있어도, "의미론적 유사도"를 정확히 감지해 관련 청크(Top 3~5)를 추출해 냅니다.

STEP 04. CONTEXT INJECTION & LLM GENERATION

④ 프롬프트 조립 및 LLM 생성 (답변 도출)

벡터 DB에서 찾아낸 실제 텍스트 조각들을 ****시스템 컨텍스트(배경 지식)****로 선언하고, 사용자의 본질적인 질문과 유기 결합하여 하나의 완성도 높은 프롬프트 패키지를 실시간 제작해 LLM에 정밀 투입합니다.

ASSEMBLED PROMPT FOR LLM

"당신은 사내 지식 도우미입니다.

****[컨텍스트: 복지 규정 2단계에서 검색된 실제 텍스트 청크]****

위의 신뢰할 수 있는 사실 컨텍스트 자료에만 의거하여 사용자의 질문인 *****우리 회사 복지 혜택이 뭐야?*****에 대해 왜곡이나 거짓(환각) 없이 정확히 한국어로 답변하십시오."

할루시네이션 종결: LLM은 학습된 두뇌 능력을 사용하되 지식 정보 소스는 오직 주어진 자료에만 복종하므로, 가짜 정보를 지어내는 인공지능의 취약점을 혁신적으로 종결합니다.