

깔끔한 데이터(Tidy Data)의 3대 규칙

㉑ 1. 변수는 Column

각각의 독립된 변수는 고유한 열(Column)로 구성되어야 합니다. 속성이나 특성별로 열이 분리되어야 분석이 용이합니다.

㉒ 2. 관측값은 Row

개별 관측 대상이나 이벤트는 각각 하나의 행(Row)으로 구성되어야 합니다. 데이터의 단위 행이 명확해야 합니다.

■ 3. 값은 Cell

모든 데이터 셀(Cell)에는 단 하나의 값만 작성되어야 합니다. 여러 값이 혼재된 복합 셀은 전처리를 통해 분리합니다.

사례 1: 열 이름이 값인 경우 (Wide → Long)

비깔끔한데이터 (Wide Type)

지역	2021	2022	2023
서울	10	12	15
부산	7	9	11

문제점: 연도별 비교 및 시각화 시 X축 매핑이 왜곡됨

깔끔한데이터 (Long Type)

지역	연도	값
서울	2021	10
서울	2022	12
부산	2021	7

해결책: 연도를 하나의 변수 열로 통합하여 구조 변경

사례 2: 하나의 셀에 여러 값이 있는 경우

비깔끔한데이터

이름	성별_나이
철수	남_20
영희	여_22

문제점: 성별과 나이가 하나의 셀에 혼재되어 독립 연산 불가

깔끔한데이터

이름	성별	나이
철수	남	20
영희	여	22

해결책: 문자열 분리(Split)를 통해 각각의 변수 열로 분할

사례 3: 피벗과 다중 집계(Aggregation)

집계 전 데이터 (중복 관측 존재)

지역	연도	월	판매액
서울	2021	1	5
서울	2021	2	7
서울	2022	1	12
부산	2021	1	7
부산	2022	2	11

문제점: (지역, 연도) 조합이 유일하지 않고 월별로 분산됨

pivot_table() 결과 (총판매액, 평균판매액)

지역	총판매액		평균판매액	
	2021	2022	2021	2022
서울	12	12	6.0	12.0
부산	7	11	7.0	11.0

해결책: aggfunc=["sum", "mean"]을 이용한 다중 집계 피벗