

평균. 분산. 표준편차

평균의 함정

극단적인 값(아웃라이어)이나 데이터의 불균형한 분포로 인해
평균값이 전체 데이터의 실체를 제대로 반영하지 못하고 왜곡하는 현상

[사례]

1985년도 노스캐롤라이나 대학교 지리학과 졸업생의 평균 초봉이 10만 달러였습니다.

우리 돈으로 따지면 지금 환율 기준으로 무려 1억 천만원이 넘는데요,

1985년도 1억 천만원이라는 금액은 상당히 큰 액수입니다.

이 학생들에게 이렇게 많은 평균 연봉이 책정된 이유는 무엇일까?

그 이유는 졸업생 중에 **NBA 농구 선수 마이클 조던**이 포함되어
때문입니다. 마이클 조던 한명이 평균 연봉 값을 올렸던 것이죠.
이것이 평균의 함정입니다.



평균 mean

평균은 모든 값을 더한 후 개수로 나눈 수치로, **엑스바** 라고 읽음.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

예시:

5명의 월급이 200, 250, 300, 350, 1,000만 원일 때, 평균은 **약 420만 원**.

$$\bar{x} = \frac{200 + 250 + 300 + 350 + 1,000}{5} = 420$$

하지만 4명은 평균보다 훨씬 적게 받음. 1,000이라는 극단적인 값(억대 연봉자)이 평균을 끌어올린 것임.

평균의 함정 피하기

통계적 딜레마: 평균이 같다고 데이터의 성격이 같은 것은 아님.

데이터가 평균 주위에 밀집되어 있는지, 넓게 퍼져 있는지 알 수 없음.

평균의 함정을 피하는 방법

1. 표준편차를 확인한다:

평균과 표준편차를 함께 보면 데이터의 실제 형태를 이해할 수 있음.

2. 중앙값 (Median) 활용: 극단적인 이상치가 있는 경우,

순서대로 나열했을 때 가장 중앙에 있는 값(중앙값)이 평균보다 더 정확한 '평균'을 나타낼 수 있습니다.

3. 데이터 시각화:

히스토그램이나 박스 플롯(Box plot)을 그려 데이터의 분포를 직접 확인

분산 variance

분산은 데이터가 평균에서 얼마나 떨어져 있는지를 보여주는 수치

정의: 편차(데이터 - 평균)의 제곱을 모두 더한 후, 그 개수로 나눈 값입니다 (평균과의 거리에 대한 제곱 평균).

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

의미: 분산이 작으면 데이터가 평균에 가깝게 밀집되어 있고, 분산이 크면 평균에서 멀리 흩어져 있음.

단점: 제곱을 하기 때문에 실제 데이터 단위보다 훨씬 큰 값이 되어 직관적인 해석이 어려움

표준편차 Standard Deviation

분산에 루트(Square Root)를 씌운 값

분산은 계산 과정에서 단위를 제공했기 때문에 실제 데이터의 단위와 달라짐

(예: cm를 제공하면 cm²이 됨). 여기에 루트를 씌워 다시 원래 데이터와 단위(Scale)를 맞추기 위해 사용

$$\sigma = \sqrt{\sigma^2}$$

평균, 편차, 편차제곱, 분산, 표준편차

평균, 분산, 표준편차

Start	1년	2년	3년	4년	5년
1년간	175	177	179	181	183
평균 $(\frac{1\text{년간의 합}}{\text{인원수}})$	$= \frac{175+177+179+181+183}{5} = 179$				
편차 $(1\text{년간}-\text{평균})$	$175-179$ $= -4$	$177-179$ $= -2$	$179-179$ $= 0$	$181-179$ $= 2$	$183-179$ $= 4$
편차제곱 $(\text{편차} \times \text{편차})$	$(-4) \times (-4)$ $= 16$	$(-2) \times (-2)$ $= 4$	$(0) \times (0)$ $= 0$	$(2) \times (2)$ $= 4$	$(4) \times (4)$ $= 16$
분산 (편차제곱의 평균)	$= \frac{16+4+0+4+16}{5} = \frac{40}{5} = 8$				
표준편차 $(\sqrt{\text{분산}})$	$= \sqrt{8} \approx 2.828$				
결론	인원수=5, 평균=179, 분산=8, 표준편차=2.828				

표준편차 활용사례

평균.분산.표준편차를 실제 마케팅 데이터에 어떻게 활용할 수 있을까?

평균 거래액이 20,000원인 유저 그룹의 평균 거래액을 26,000원으로 **6,000원** 올리는 것과
평균 거래액이 50,000원인 유저 그룹의 평균 거래액을 60,000원으로 **10,000원** 올리는 것 중 무엇이 더 어려울까?

-3SD	-2SD	-1SD	평균	+1SD	+2SD	+3SD
₩14,000	₩16,000	₩18,000	₩20,000	₩22,000	₩24,000	₩26,000

평균 거래액이 20,000원이고 표준편차가 2,000원인
경우

-3SD	-2SD	-1SD	평균	+1SD	+2SD	+3SD
₩35,000	₩40,000	₩45,000	₩50,000	₩55,000	₩60,000	₩65,000

평균 거래액이 50,000원이고 표준편차가 5,000원인
경우

표준편차 활용사례

평균.분산.표준편차를 실제 마케팅 데이터에 어떻게 활용할 수 있을까?

평균 거래액이 20,000원인 유저 그룹의 평균 거래액을 26,000원으로 **6,000원** 올리는 것과

평균 거래액이 50,000원인 유저 그룹의 평균 거래액을 60,000원으로 **10,000원** 올리는 것 중 무엇이 더 어려울까?

-3SD	-2SD	-1SD	평균	+1SD	+2SD	+3SD
₩14,000	₩16,000	₩18,000	₩20,000	₩22,000	₩24,000	₩26,000

평균 거래액이 20,000원이고 표준편차가 2,000원인
경우

-3SD	-2SD	-1SD	평균	+1SD	+2SD	+3SD
₩35,000	₩40,000	₩45,000	₩50,000	₩55,000	₩60,000	₩65,000

평균 거래액이 50,000원이고 표준편차가 5,000원인
경우